

# SCC0276 - Aprendizado de Máquina

## Aula PCA

Profa. Dra. Roseli Aparecida Francelin Romero  
SCC - ICMC - USP

2019

# Sumário

1 Introduction

2 Transformação dos Dados

3 A técnica PCA

4 Propriedades

## Tratamento de Dados

- Permite reduzir a dimensão dos dados:  
 $x_1, x_2, \dots, x_n \longrightarrow t_1, t_2, \dots, t_p ; p \leq n$
- $t_1, t_2, \dots, t_p$  são ortogonais (sem correlação)
- Mantendo a variancia dos dados

# Tratamento de Dados

- Requer uma transformação dos dados
- Os dados devem estar com  $\text{media} = 0$  e  $\text{variancia} = 1$

# Sumário

1 Introduction

2 Transformação dos Dados

3 A técnica PCA

4 Propriedades

## Média e Variância

- $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$
- Dados centrados na média e variancia igual a 1:

$$x_{ij} = \frac{(x_{ij} - \bar{x}_j)}{\sigma_j}$$

# Sumário

1 Introduction

2 Transformação dos Dados

3 A técnica PCA

4 Propriedades

# PCA

- Determinar a matriz de covariancia dos dados
- Determinar os auto-valores e respectivos auto-vetores
- os coeficientes do auto-vetor correspondente ao maior auto-valor formarão os coeficientes da componente principal  $Z_1$ .
- os coeficientes do auto-vetor correspondente ao segundo maior auto-valor formarão os coeficientes da 2a. componente principal,  $Z_2$ .
- e assim, sucessivamente.



# PCA

- **Objetivo:** Dadas  $n$  variáveis, deseja-se achar combinações lineares dessas, para produzir índices que sejam não correlacionados, de tal forma que: Índices  $Z_i$ : componentes principais.

# PCA

- i-ésima componente principal
- $Z_i = a_{i1}X_1 + a_{i2}X_2 + \dots + a_{in}X_n$
- com a seguinte propriedade:  $a_{i1}^2 + a_{i2}^2 + \dots + a_{in}^2 = 1$
- $Z_1, Z_2, \dots, Z_p$  são não correlacionados

# PCA

- PCA: resume-se em encontrar os autovalores e autovetores da matriz  $C$  de covariância dos dados
- Supondo que: os autovalores da matriz  $C$  estejam ordenados da seguinte forma:

$$\lambda_1 \geq \lambda_2 \geq \dots = \lambda_n$$

- Os auto-vetores associados:

$$a_1, a_2, \dots, a_n$$

# Sumário

- 1 Introduction
- 2 Transformação dos Dados
- 3 A técnica PCA
- 4 Propriedades

# Propriedades



$$a_i^T a_j = \begin{cases} 0 & i = j \\ 1 & i \neq j \end{cases}$$

- a soma dos auto-valores correspondem ao traço da matriz de covariância:

$$\lambda_1 + \lambda_2 + \dots + \lambda_n = c_{11} + c_{22} + \dots + c_{nn}$$



$$\text{var}(Z_i) = \lambda_i$$

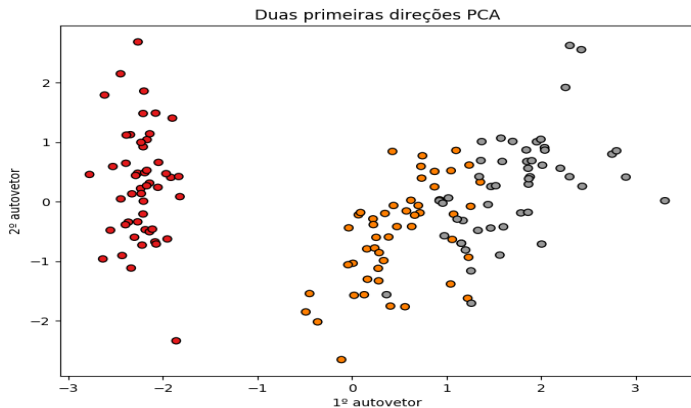


Figura 1: Duas componentes principais do iris.dat

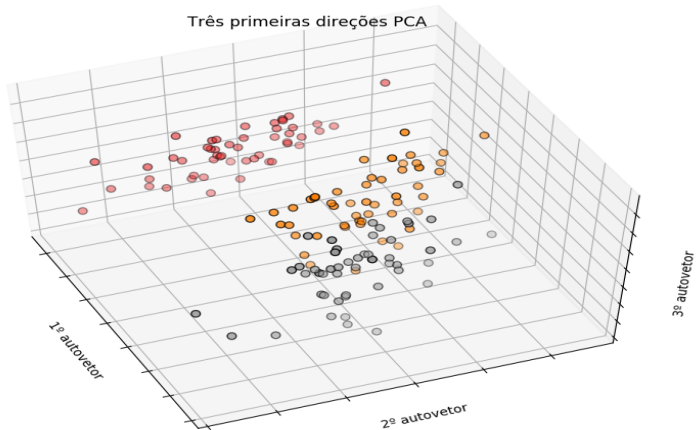


Figura 2: Duas componentes principais do iris.datr

## Exercicio

- Encontrar as 2 componentes principais para o conjunto iris.dat. Verificar que as duas juntas representam 95.80% da variancia dos dados.