

SCC0276 - Aprendizado de Máquina

Aula Regressão Logística

Profa. Dra. Roseli Aparecida Francelin Romero
SCC - ICMC - USP

2019

Sumário

1 Introdução

2 Função Custo

3 Otimização

CLASSIFICAÇÃO

- Um **hipótese** para aprox. os dados (uma função)
- Uma **função custo** (que determinará o desempenho da hipótese)
- Um **algoritmo de otimização** para os ajustar os coeficientes ou pesos da hipótese.

CLASSIFICAÇÃO

- $h(x) = w_0 + w_1.x_1 + w_2.x_2$; ótimo na regressão linear pois temos que prever um valor contínuo,
- Na classificação temos que classificar ou categorizar em SIM=1 ou NÃO=0 (valor binários).

Tabela de Inscrições

exam1_score	exam2_score	admitted
34.62365962451697	78.0246928153624	0
30.28671076822607	43.89499752400101	0
35.84740876993872	72.90219802708364	0
60.18259938620976	86.30855209546826	1
79.0327360507101	75.3443764369103	1
45.08327747668339	56.3163717815305	0
61.10666453684766	96.51142588489624	1
75.02474556738889	46.55401354116538	1
76.09878670226257	87.42056971926803	1

Figura 1: Tabela de notas de candidatos

CLASSIFICAÇÃO

- Mais concretamente, em nosso problema acima, precisamos produzir um “sim”, sinalizando que o aluno será ACEITO, ou “não”, sinalizando que o aluno NÃO FOI ACEITO. O Não podemos dizer, simplesmente, 45% “sim”!
- Matematicamente, podemos codificar esta informação em nossa equação (de $h(x)$) aplicando uma função sigmóide.





Figura 2: Função Sigmoid

Função Logística ou Sigmoid



- O alcance da função logística, como podemos ver, está entre 0 e 1. Portanto, se quisermos passar nossa saída de $h(x)$ para a função logística, estaremos limitando o intervalo a $[0, 1]$.

-

$$g(h(x)) = 1/(1 + \exp(-h(x)))$$

$$g(h(x)) = 1/(1 + \exp(-w_0 - w_1 \cdot x_1 - w_2 \cdot x_2))$$

Função Logística

- Não é suficiente limitar o intervalo de $h(x)$ a $[0, 1]$. Precisamos gerar um SIM (1) ou um NÃO (0). Para conseguir isso, devemos primeiro observar como a saída da função logística é.
- Fica claro que a curva é simétrica em torno de $y = 0,5$.
- Portanto, podemos afirmar com segurança que, se a saída da função logística for maior que 0,5, podemos tratá-la como "SIM" e, se for menor ou igual a 0,5, podemos tratá-la como "NÃO". Formalmente falando, envie 'SIM' se: $g(h(x)) > 0,5$

Função Logística

- $g(h(x)) > 0.5 \quad h(x) > 0$
- o que significa: $w_0 + w_1x_1 + w_2x_2 > 0$
- $w_0 + w_1x_1 > -w_2x_2$
- $\left(\frac{-w_0}{w_2}\right) + \left(\frac{-w_1}{w_2}\right) \cdot x_1 > x_2$
- $c + mx > y \quad c = \frac{-w_0}{w_2},$

$$m = \frac{-w_1}{w_2}, \quad x = x_1 \text{ and } y = x_2$$

Função Logística

- Portanto, a equação representa a parte do gráfico que está acima da linha $y = mx + c$.
- Como estávamos tentando codificar as informações de "SIM" ou "NAO" em $g(h(x))$ - o que nos levou a um ponto em que podemos dizer que a região acima da reta $w_0 + w_1.x_1 + w_2.x_2$ é onde emitimos "SIM", e a região abaixo é onde produzimos "NÃO".

Sumário

1 Introdução

2 Função Custo

3 Otimização

Função Custo Não-Convexa

- Não podemos usar a mesma função de custo que a regressão linear:



$$J(\theta) = \frac{1}{m} \sum_1^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

- Isto porque, na equação acima, se $h(x)$ é a função logística, então $J()$ será não-convexo (devido à presença de termo exponencial na função logística):

Nova Função de Custo




Figura 3: Função não-convexa com vários pts de máximo

Nova Função de Custo

- Precisamos criar uma nova função de custo para problemas baseados em classificação
- Usando probabilidade condicional:
$$h(x) = P(y = 1, x)$$
$$1 - h(x) = P(y = 0, x) \text{ (pela regra de probabilidade complementar)}$$
- Combinando as 2 equações, obtemos:
$$P(y, x) = (h(x))^y * ((1 - h(x))^{(1-y)})$$
- Como nossa tarefa é classificação, deseja-se maximizar a probabilidade de produzir o valor correto - independentemente do valor de 'y', podemos afirmar com segurança que a equação acima é uma boa representação de como nosso modelo está se desempenhando em um dado exemplo.

Nova Função de Custo

- Para determinar nosso modelo sobre todos os exemplos, nós devemos tomar o produto da eq. para todos os exemplos:

$$P(y, x) = [(h(x)^{y(1)}) * ((1 - h(x))^{(1-y(1))})] * [(h(x)^{y(2)}) * ((1 - h(x))^{(1-y(2))})] * [(h(x)^{y(3)}) * ((1 - h(x))^{(1-y(3))})] \dots * [(h(x)^{y(N)}) * ((1 - h(x))^{(1-y(N))})]$$

onde $y(1), y(2), \dots, y(N)$ são N examples do nosso dataset.

Nova Função de Custo

- Para se livrar do produto e exponenciais, aplicando uma transformação de log para simplificar a equação:

$$\log(P(y, x)) = \sum (\log((h(x)^{y(i)}) * ((1 - h(x))^{(1-y(i))})))$$

$$\log(P(y, x)) = \sum (\log(h(x)^{y(i)}) + \log((1 - h(x))^{(1-y(i))}))$$

$$\log(P(y/x)) = \sum (y(i)\log(h(x)) + (1 - y(i))\log((1 - h(x))))$$

Esta equação é nova função custo e é conhecida com **cross-entropy cost function. FUNÇÃO CONVEXA**

Nova Função de Custo




Figura 4: Função convexa

Sumário

1 Introdução

2 Função Custo

3 Otimização

Otimização

- Semelhante à Regressão Linear, podemos usar o Gradient Descent para otimizar nossa função de custo de entropia cruzada, sem nos preocuparmos com o fato de nosso modelo ficar preso a um ótimo local.